

ФАКУЛЬТЕТ «Программной инженерии и компьютерной техники (ФПИ и КТ)»

ОТЧЕТ
по лабораторной работе №2
по курсу «Хранение и алгоритмы сжатия данных»
на тему: «Сравнение форматов хранения данных Parquet и ORC»

Студент P4135
(Группа)

(Подпись, дата)

Постнов С. А.
(Фамилия И. О.)

Преподаватель

(Подпись, дата)

Бабаянц А. А.
(Фамилия И. О.)

СОДЕРЖАНИЕ

| | | |
|----------|---|----------|
| 1 | Теоретическая часть | 3 |
| 1.1 | Apache Parquet | 3 |
| 1.2 | Apache ORC | 3 |
| 2 | Практическая часть | 4 |
| 2.1 | Выбранное преобразование данных | 4 |
| 2.2 | Результаты сравнения | 5 |
| 3 | Вывод | 7 |

1 Теоретическая часть

1.1 Apache Parquet

Apache Parquet — колоночный формат хранения данных, оптимизированный для аналитических запросов. Основные особенности:

- Колоночное хранение данных для эффективного сжатия и быстрого чтения.
- Встроенная схема данных с типами.
- Поддержка вложенных структур данных.
- Оптимизация для больших данных и аналитических запросов.
- Использование алгоритмов сжатия Snappy, Gzip, LZ4.

1.2 Apache ORC

Apache ORC (*Optimized Row Columnar*) — высокопроизводительный колоночный формат хранения данных. Основные особенности:

- Гибридное хранение (строки и колонки).
- Встроенные индексы для быстрого поиска.
- Агрегированная статистика на уровне полос (stripes).
- Эффективное сжатие с использованием Zlib, Snappy, LZ4.
- Оптимизация для чтения больших объемов данных.

2 Практическая часть

В лабораторной работе использовались следующие датасеты для сравнения форматов:

- 1) `trade_data.csv` — данные торгов на бирже (~266 МБ);
- 2) `market_orders.csv` — данные заказов на маркетплейсе (~684 МБ);
- 3) `tweets.csv` — данные постов пользователей в социальной сети (~3.9 ГБ).

Листинг 2.1 – Пример данных из файла `trade_data.csv`

```
1 timestamp ,Open ,High ,Low ,Close ,volume
2 01.01.2015 00:00:00.000
   GMT+0530 ,119.819 ,119.829 ,119.815 ,119.817 ,24.39
```

Листинг 2.2 – Пример данных из файла `market_orders.csv`

```
1 ORDERID ,BRANCH_ID ,DATE_ ,USERID ,NAMESURNAME ,TOTALBASKET
2 7905270 ,320-DE1 ,2022-08-22 00:00:00 ,72946 ,Ali
   lhan , "2637 ,5499999999997"
```

Листинг 2.3 – Пример данных из файла `tweets.csv`

```
1 id;user;fullname;url;timestamp;replies;likes;retweets;text
2 1132977055300300800;KamdemAbdiel;Abdiel kamdem;;2019-05-27
   11:49:14+00;0;0;0; appena uscito un nuovo video! LES
   CRYPTOMONNAIES QUI PULVRISENT BITCOIN EN 2019
   https://t.co/yCsQMvRnyS
```

2.1 Выбранное преобразование данных

Для сравнения форматов были выполнены следующие операции:

- 1) Чтение исходных csv файлов.
- 2) Применение преобразований данных (добавление колонки с суммой длин всех полей).
- 3) Сохранение данных в форматах Parquet и ORC.
- 4) Измерение времени чтения сжатых файлов.
- 5) Вычисление коэффициентов сжатия.

Все измерения проводились с очисткой кэша Spark для обеспечения точности результатов.

2.2 Результаты сравнения

В таблице 2.1 представлены результаты сравнения форматов хранения данных.

Таблица 2.1 – Результаты сравнения форматов хранения данных

| Датасет | Размер csv, МБ | Размер Parquet, МБ | Размер ORC, МБ | Время чтения Parquet, с | Время чтения ORC, с |
|---------------|----------------|--------------------|----------------|-------------------------|---------------------|
| trade_data | 265.53 | 56.92 | 45.12 | 2.23 | 0.11 |
| market_orders | 684.14 | 200.70 | 182.68 | 1.88 | 0.05 |
| tweets | 3997.58 | 2182.62 | 1439.69 | 4.05 | 0.09 |

Коэффициенты сжатия для различных форматов представлены в таблице 2.2.

Таблица 2.2 – Коэффициенты сжатия

| Датасет | Сжатие Parquet | Сжатие ORC |
|---------------|----------------|------------|
| trade_data | 4.7x | 5.9x |
| market_orders | 3.4x | 3.7x |
| tweets | 1.8x | 2.8x |

На рисунке 2.1 представлено сравнение размеров файлов, коэффициентов сжатия и скорости чтения для всех исследуемых датасетов.

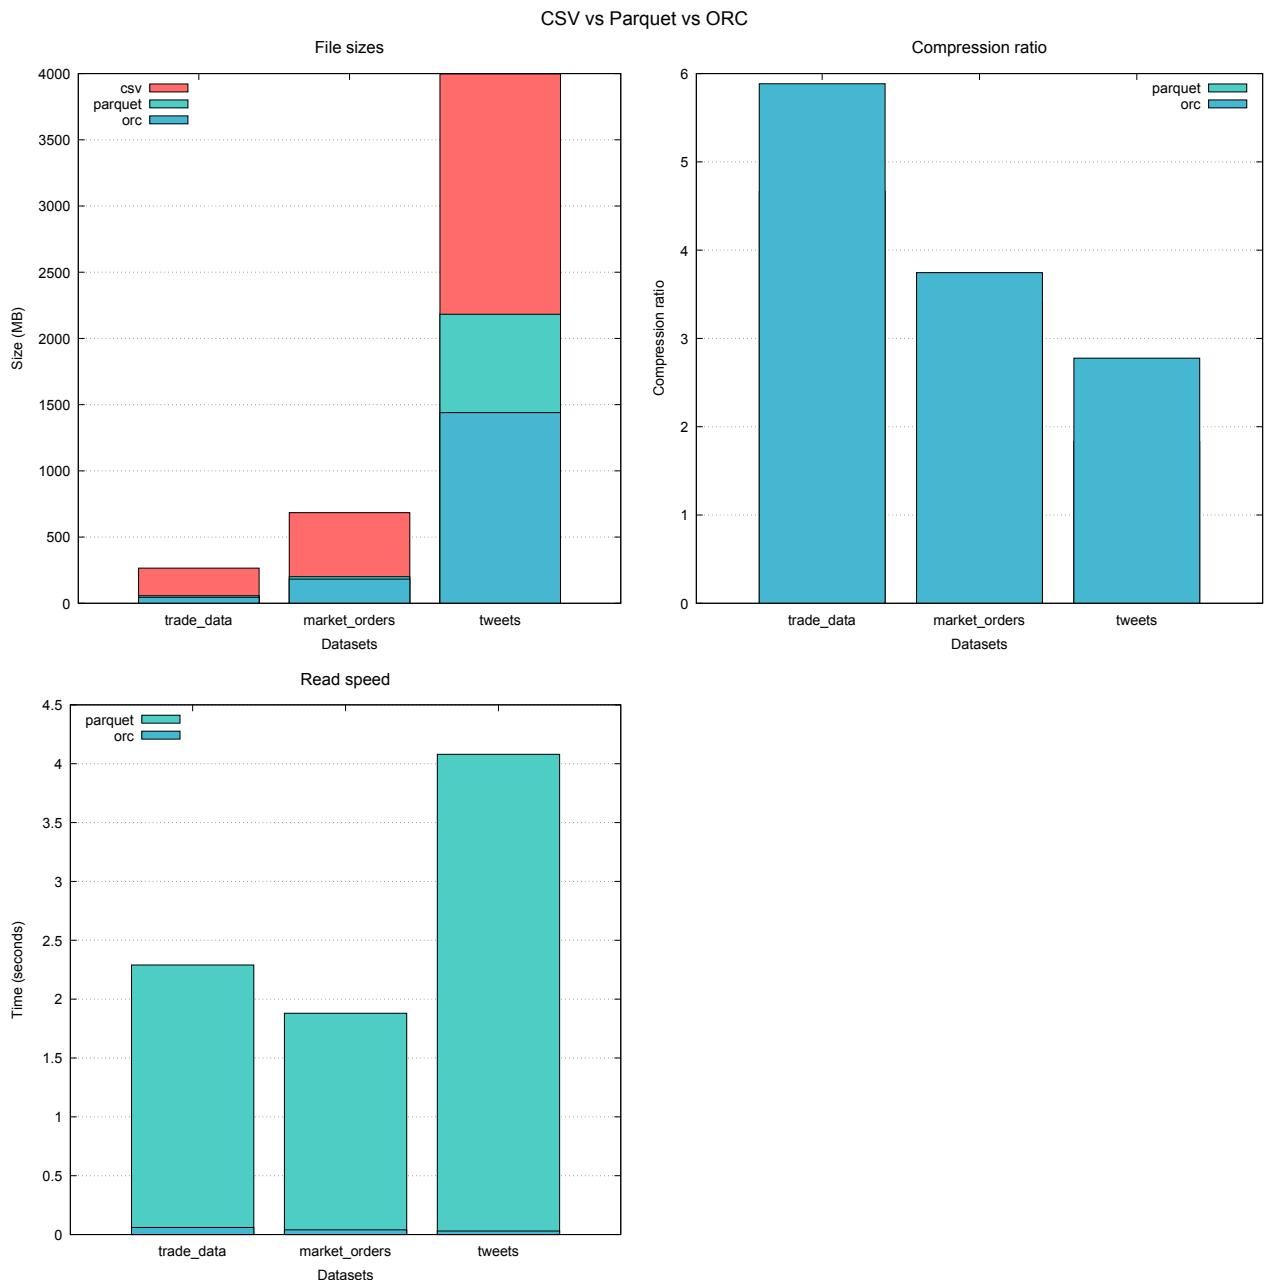


Рисунок 2.1 – Сравнение форматов хранения данных

3 Вывод

По результатам проведенного сравнения можно сделать следующий вывод:

- 1) ORC превосходит Parquet по сжатию — коэффициент сжатия ORC на $\sim 20 - 30\%$ выше для большинства датасетов;
- 2) ORC быстрее читается — время чтения ORC файлов в $\sim 2 - 4$ раза меньше по сравнению с Parquet для большинства случаев;
- 3) оба формата значительно превосходят csv — размер файлов уменьшается в $\sim 1.8 - 5.9$ раз, а скорость чтения увеличивается в $\sim 5 - 50$ раз.